

图5 误差沿深度逐层累积 | Fig. 5 Layer-wise error accumulation




图5 全局注入 $\alpha = \pm 0.4$ 时各层输出激活相对于干净前向的相对 L2 误差（基线模型，128 样本批，activation hook 逐层对比）。误差自 layer4.0.downsample.0 起才非零并沿深度快速放大，至 fc 输入处

$\alpha = -0.4$ 达 0.978、 $\alpha = +0.4$ 达 0.605——与实证核验的“实际仅 4 个深层生效”完全一致。该图支持的结论：非线性误差在深层被逐级放大，且负 α 在激活幅值上造成的相对扰动大于正 α ，但正 α 因压缩语义信息而导致更大的准确率损失（对照图3、图6）。